

Projeto Integrador — Banco de Dados AWS

Respostas às Questões de Análise Descritiva e de Sentimento

1. Carregamento e Entendimento dos Dados

Quais as dimensões de cada tabela (quantidade de variáveis e informações)?

O conjunto de dados é composto por nove tabelas com diferentes quantidades de registros e colunas. Entre elas, a tabela **geolocalizacao** se destaca por possuir mais de 1 milhão de registros, sendo a maior da base. Já a **tabela_auxiliar** é a menor, contendo apenas 71 registros. As demais tabelas apresentam volumes intermediários e armazenam informações relacionadas a clientes, pedidos, produtos, pagamentos, avaliações e vendedores.

Quais tabelas possuem textos (comentários, nomes de produtos, entre outros)?

Ao verificar os tipos de dados presentes nas tabelas, foi possível observar que praticamente todas possuem colunas textuais, como nomes, categorias, identificadores e comentários. A única exceção é a tabela **geolocalizacao**, que não contém campos destinados a textos descritivos.

Quais tabelas possuem valores numéricos (preço, frete, parcelas)?

A maior parte das tabelas apresenta pelo menos uma coluna numérica. As informações financeiras estão concentradas principalmente nas tabelas **itens_pedidos** e **pagamentos**, que armazenam valores relacionados a preço dos produtos, frete e formas de pagamento.

Quais limitações são identificadas nos dados (faltantes, repetidos ou colunas mal preenchidas)?

Durante a análise inicial foram encontrados valores nulos em algumas tabelas, principalmente na de avaliações, onde muitos clientes não preencheram comentários ou títulos. Também foram observados registros repetidos de CEPs na tabela de geolocalização, embora não existam linhas totalmente duplicadas. Esses fatores podem exigir tratamentos específicos antes da realização de análises mais aprofundadas.

Para que serve cada tabela dentro do fluxo de um e-commerce?

Cada tabela representa uma etapa do processo de compra dentro do marketplace. A tabela de clientes armazena os dados dos compradores, enquanto a de produtos reúne o catálogo disponível para venda. Os pedidos registram as compras realizadas, e os itens dos pedidos detalham os produtos adquiridos em cada compra. A tabela de pagamentos contém informações sobre a forma de pagamento utilizada, e a de avaliações registra a opinião do cliente após a entrega. Já a tabela de geolocalização auxilia em análises relacionadas à logística e distribuição.

Quais colunas funcionam como chaves primárias e estrangeiras?

As tabelas possuem uma estrutura relacional bem definida. Os identificadores principais incluem campos como **customer_id**, **order_id**, **product_id**, **seller_id** e **review_id**. Esses campos são utilizados

para conectar as tabelas entre si, permitindo a realização de consultas e análises integradas sobre clientes, pedidos, produtos, pagamentos e avaliações.

Alguma coluna precisa de descrição ou nome mais claro para o dicionário de dados?

Sim. Algumas colunas possuem nomes que podem gerar dúvidas para quem está consultando a base pela primeira vez. Um exemplo é **customer_unique_id**, que representa o cliente real independentemente de possíveis cadastros diferentes. Também seria interessante utilizar nomes mais intuitivos para os campos relacionados aos comentários das avaliações.

2. Perguntas sobre Código

Como analisar de forma geral as informações de cada tabela?

Uma maneira eficiente de realizar essa análise é utilizar uma função que reúna os principais métodos de exploração do Pandas, como visualização das primeiras linhas, tipos de dados, estatísticas descritivas e quantidade de valores nulos. Dessa forma é possível obter uma visão geral da estrutura de cada tabela.

Como listar valores únicos de uma coluna específica?

Para visualizar os valores diferentes existentes em uma coluna pode-se utilizar o método `.unique()`. Caso o objetivo seja apenas saber quantos valores distintos existem, o método `.nunique()` é uma boa alternativa.

Como identificar rapidamente se existem linhas duplicadas?

O método `.duplicated()` permite identificar registros repetidos em uma tabela. Além de contar essas ocorrências, também é possível visualizar quais linhas estão duplicadas ou realizar a verificação com base em colunas específicas.

Como contar a quantidade total de valores nulos por coluna?

A contagem de valores ausentes pode ser feita utilizando o método `.isnull().sum()`. Esse procedimento ajuda a identificar quais colunas precisam de maior atenção durante a etapa de limpeza dos dados.

Como verificar os tipos de dados de cada tabela?

Os tipos de dados podem ser analisados com o método `.info()`, que apresenta informações detalhadas sobre cada coluna, incluindo tipo de dado, quantidade de registros preenchidos e uso de memória.

Como visualizar as primeiras, últimas linhas de uma tabela? E uma amostra?

As primeiras linhas podem ser exibidas com `.head()`, enquanto as últimas podem ser visualizadas com `.tail()`. Para selecionar registros aleatórios da tabela, utiliza-se o método `.sample()`, que permite gerar uma amostra dos dados.

3. Perguntas de Conclusão

Todas as tabelas foram carregadas corretamente? Alguma apresentou erro ou comportamento inesperado?

Todas as tabelas foram carregadas sem problemas durante a leitura dos arquivos. O principal destaque foi a tabela de geolocalização, que possui um volume de dados muito superior ao das demais, exigindo maior atenção em análises e junções.

Os tipos de dados foram reconhecidos corretamente pelo pandas?

De forma geral, sim. Entretanto, as colunas de data foram carregadas inicialmente como texto e precisaram ser convertidas para o formato adequado. Algumas colunas categóricas também podem ser ajustadas para melhorar o desempenho e o consumo de memória.

O que foi percebido de mais importante sobre a estrutura geral das tabelas?

A base apresenta uma estrutura relacional bastante organizada, semelhante à encontrada em plataformas reais de marketplace. Um dos pontos mais relevantes observados foi a grande quantidade de avaliações sem comentários, o que pode limitar determinadas análises de sentimento.

Quais relações entre as tabelas parecem essenciais para analisar um pedido completo?

Para compreender todo o ciclo de uma compra é necessário relacionar principalmente as tabelas de clientes, pedidos, itens dos pedidos, produtos e pagamentos. As avaliações complementam essa visão ao mostrar a percepção do cliente após a compra.

Que partes dos dados provavelmente precisarão de limpeza mais adiante?

As principais etapas de limpeza envolvem o tratamento de valores nulos, a conversão correta das datas, a padronização de informações de localização e a resolução de possíveis inconsistências em categorias de produtos.

Que dificuldades você imagina ao juntar essas tabelas?

Uma das principais dificuldades está relacionada à tabela de geolocalização, que possui múltiplos registros para determinados CEPs. Além disso, alguns pedidos não possuem informações completas de entrega ou avaliação, o que pode gerar valores ausentes após as junções.

As colunas de data estão no formato adequado para análise temporal?

Inicialmente não. Foi necessário converter essas colunas para o formato de data do Pandas. Após essa etapa, tornou-se possível realizar análises temporais, como agrupamentos por mês, cálculo de intervalos entre datas e acompanhamento da evolução dos pedidos ao longo do tempo.

4. Pesquisa e Comparação — Análise de Sentimento

O que é o compound do VADER?

O *compound* é a principal métrica utilizada pelo VADER para representar o sentimento geral de um texto. Seu valor varia entre -1 e +1, indicando desde sentimentos muito negativos até muito positivos.

Como o VADER calcula o sentimento?

O VADER utiliza um dicionário de palavras associadas a diferentes níveis de sentimento e aplica regras que consideram fatores como negações, uso de letras maiúsculas, pontuação e intensificadores. A combinação desses elementos gera uma pontuação final para o texto analisado.

Qual a diferença entre VADER e LeIA?

O LeIA foi desenvolvido com foco na língua portuguesa e adapta a lógica do VADER para esse contexto. Como resultado, consegue interpretar melhor expressões, gírias e características específicas do português brasileiro.

Há diferença entre os modelos? Qual parece mais coerente com a nota?

Sim. Durante a comparação foi possível perceber diferenças nos resultados produzidos pelos modelos. O LeIA e os modelos baseados em Transformers apresentaram resultados mais compatíveis com as notas atribuídas pelos usuários, enquanto o VADER encontrou mais dificuldades em interpretar corretamente textos escritos em português.

Um modelo em inglês funciona bem em português?

Embora possa fornecer resultados razoáveis em alguns casos, modelos desenvolvidos especificamente para o inglês tendem a apresentar limitações quando aplicados a textos em português. Isso acontece porque muitas expressões e particularidades da língua não são interpretadas adequadamente.

A escolha do modelo impacta o resultado?

Sim. A escolha do modelo influencia diretamente a classificação dos sentimentos e, consequentemente, as conclusões obtidas na análise. Por esse motivo, é importante selecionar uma ferramenta compatível com o idioma e com o contexto dos dados analisados.